

viu
.es



ACTIVIDAD

Máster en Big Data y Data Science

03MBID – Procesamiento de datos masivo


Nombre: Daniel López y Ania Gorostiza

Fecha: 27-06-2025


Preparación Máquina Virtual (VMware Workstation Pro)

Descargar VMware Workstation Pro


- Abrir el navegador web** que utilices habitualmente (Chrome, Edge, Firefox, etc.).
- Ir a la siguiente dirección: <https://www.vmware.com/products/desktop-hypervisor/workstation-and-fusion> y clicar en “Download Fusion or Workstation”.



- En 2023 Broadcom Inc adquirió VMware motive por el cual al **pulsar el botón** nos redirigirá a la siguiente página de inicio de sesión (Si no estás registrado deberás hacerlo anteriormente):
<https://access.broadcom.com/default/ui/v1/signin/verify/>
- Se abrirá tu **dashboard** personal de Broadcom y nos dirigiremos a la parte de “My Downloads”. Una vez en la pestaña clicaremos para ver los softwares gratuitos.



e. Buscamos **VMware Workstation Pro** y lo descargamos.



f. Esperar a que se complete la descarga del archivo instalador, que tendrá un nombre similar a: **VMware-workstation-full-xx.x.x-xxxxxxx.exe**

Instalar VMware Workstation Pro (en Windows)

1. Una vez descargado el archivo instalador .exe, haz doble clic sobre él para ejecutarlo.
2. Aparecerá una ventana de control de cuentas de usuario (UAC) de Windows solicitando permisos para ejecutar el instalador. Haz clic en **Sí**.
Se abrirá el asistente de instalación de VMware Workstation Pro.
3. En la primera pantalla, haz clic en **Next** (Siguiente).
4. Aparecerá el **End-User License Agreement (EULA)**.
5. Marca la casilla **I accept the terms in the license agreement** (Acepto los términos del acuerdo de licencia).
6. Haz clic en **Next** (Siguiente).
7. En la pantalla **Custom Setup**, puedes configurar algunas opciones personalizadas. Si no necesitas cambiar nada, deja las opciones por defecto.
8. Haz clic en **Next** (Siguiente).
9. Puedes especificar una carpeta diferente si no deseas instalarlo en la ubicación predeterminada.
(Generalmente C:\Program Files (x86)\VMware\VMware Workstation)
10. Si no es necesario, deja la ubicación por defecto.
11. Haz clic en **Next** (Siguiente).
12. Clicar en **Install** (instalar)




Creación de una máquina virtual en VMware Workstation

Requisitos previos

1. Descargar previamente la ISO de Ubuntu desde: <https://releases.ubuntu.com/24.04/>
2. Archivo: *ubuntu-24.04.2-desktop-amd64.iso*

Pasos a seguir

1. Haz doble clic en el acceso directo de VMware Workstation Pro o búscalo en el menú inicio.
2. En el menú principal, haz clic en **Create a New Virtual Machine** o usa el atajo **Ctrl+N**.




3. Selecciona **Typical (recommended)** (Típica - recomendada).




4. En **Installer disc image file (iso)** haz clic en **Browse** (Buscar) y selecciona la ISO de Ubuntu que descargaste:

ubuntu-24.04.2-desktop-amd64.iso



5. Asignamos el nombre de usuario junto a la contraseña que queremos para iniciar.



6. **Virtual machine name:** puedes poner por ejemplo: `Instalación`

Location: define una carpeta en tu disco donde se guardará la máquina virtual, o deja la predeterminada.

The screenshot shows the 'New Virtual Machine Wizard' dialog box, specifically the 'Name the Virtual Machine' step. The title bar says 'New Virtual Machine Wizard' with a close button. Below the title, it says 'Name the Virtual Machine' and 'What name would you like to use for this virtual machine?'. There is a text input field for 'Virtual machine name:' containing the text 'Instalación'. Below that is a 'Location:' section with a text input field containing 'C:\Users\DANI\OneDrive\Documentos\Virtual Machines\Instalació' and a 'Browse...' button. A note below the location field states: 'The default location can be changed at Edit > Preferences.' At the bottom, there are three buttons: '< Back', 'Next >', and 'Cancel'.


7. Configuramos el tamaño del disco virtual:

- **Maximum disk size (GB):** 40 GB (o más si tienes espacio disponible).
- **Store virtual disk as a single file:** Recomendado para mayor rendimiento (aunque los archivos ocuparán más espacio continuo en disco).

The screenshot shows the 'New Virtual Machine Wizard' dialog box, specifically the 'Specify Disk Capacity' step. The title bar says 'New Virtual Machine Wizard' with a close button. Below the title, it says 'Specify Disk Capacity' and 'How large do you want this disk to be?'. There is a text input field for 'Maximum disk size (GB):' containing the value '40'. Below this, it says 'Recommended size for Ubuntu 64-bit: 20 GB'. There are two radio button options: 'Store virtual disk as a single file' (which is selected) and 'Split virtual disk into multiple files'. Below the second option, there is a note: 'Splitting the disk makes it easier to move the virtual machine to another computer but may reduce performance with very large disks.' At the bottom, there are four buttons: 'Help', '< Back', 'Next >', and 'Cancel'.

8. Personalizamos el hardware:


- **Memory:** asigna mínimo **4096 MB (4 GB)**, recomendado **8192 MB (8 GB)** si tu PC lo permite.
- **Processors:** 2 núcleos mínimo, ideal 4 si tienes un CPU de varios núcleos.
- **Network Adapter:** NAT o Bridged según quieras compartir red con tu PC anfitrión o red propia.
- Confirmar que el **CD/DVD (ISO)** está apuntando a la ISO de Ubuntu.
- Opcional: activar **Accelerate 3D graphics**.




9. Finalizamos la creación.

Instalación Ubuntu

1. Iniciamos la máquina virtual que hemos creado clicando sobre **Power On**.
2. Una vez iniciada nos aparecerá la opción: **Install Ubuntu** (para instalarlo en el disco virtual).
3. Empezamos la instalación seleccionando el idioma del sistema (Inglés preferiblemente).



4. Selecciona tu **distribución de teclado** (por defecto suele detectar bien, pero puedes probarlo en la caja de texto).



5. Crear usuario y contraseña:

- **Tu nombre**
- **Nombre del equipo** (nombre para identificar la máquina en la red)
- **Nombre de usuario**
- **Contraseña**
- **Confirmar contraseña**

6. Selecciona tu ubicación en el mapa o escríbela (por ejemplo **Barcelona**, **Buenos Aires**, **Madrid...**).

7. Clicar en **Install**.

Instalación de Hadoop en la Máquina Virtual

1. Instalar Java Hadoop requiere Java 8 o 11, y se recomienda OpenJDK 11 para Hadoop 3.3.6. Abrimos la terminal. Actualizamos la lista de paquetes disponibles y sus versiones con el siguiente comando: `sudo apt update`

```
dani@dani-VMware-Virtual-Platform: ~
dani@dani-VMware-Virtual-Platform:~$ sudo apt update
[sudo] password for dani:
Hit:1 http://es.archive.ubuntu.com/ubuntu noble InRelease
Hit:2 http://security.ubuntu.com/ubuntu noble-security InRelease
Hit:3 http://es.archive.ubuntu.com/ubuntu noble-updates InRelease
Hit:4 http://es.archive.ubuntu.com/ubuntu noble-backports InRelease
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
105 packages can be upgraded. Run 'apt list --upgradable' to see them.
dani@dani-VMware-Virtual-Platform:~$
```

2. Instalamos Java con el siguiente comando: `sudo apt install openjdk-11-jdk -y`

```
dani@dani-VMware-Virtual-Platform: ~
dani@dani-VMware-Virtual-Platform:~$ sudo apt install openjdk-11-jdk -y
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
The following additional packages will be installed:
  ca-certificates-java fonts-dejavu-extra java-common libatk-wrapper-java
  libatk-wrapper-java-jni libice-dev libpthread-stubs0-dev libsm-dev
  libx11-dev libxau-dev libxcb1-dev libxdmcp-dev libxt-dev
  openjdk-11-jdk-headless openjdk-11-jre openjdk-11-jre-headless x11proto-dev
  xorg-sgml-doctools xtrans-dev
Suggested packages:
  default-jre libice-doc libsm-doc libx11-doc libxcb-doc libxt-doc
  openjdk-11-demo openjdk-11-source visualvm fonts-ipafont-gothic
  fonts-ipafont-mincho fonts-wqy-microhei | fonts-wqy-zenhei fonts-indic
The following NEW packages will be installed:
  ca-certificates-java fonts-dejavu-extra java-common libatk-wrapper-java
  libatk-wrapper-java-jni libice-dev libpthread-stubs0-dev libsm-dev
  libx11-dev libxau-dev libxcb1-dev libxdmcp-dev libxt-dev openjdk-11-jdk
  openjdk-11-jdk-headless openjdk-11-jre openjdk-11-jre-headless x11proto-dev
  xorg-sgml-doctools xtrans-dev
0 upgraded, 20 newly installed, 0 to remove and 105 not upgraded.
Need to get 123 MB of archives.
After this operation, 276 MB of additional disk space will be used.
```

3. Comprobamos que se ha instalado la versión: `java -version`

```
dani@dani-VMware-Virtual-Platform:~$ java -version
openjdk version "11.0.27" 2025-04-15
OpenJDK Runtime Environment (build 11.0.27+6-post-Ubuntu-0ubuntu124.04)
OpenJDK 64-Bit Server VM (build 11.0.27+6-post-Ubuntu-0ubuntu124.04, mixed mode,
sharing)
```


4. Vamos a la carpeta personal con el comando `cd`. Una vez en la carpeta personal descargamos hadoop desde apache con el siguiente comando:

wget <https://downloads.apache.org/hadoop/common/hadoop-3.3.6/hadoop-3.3.6.tar.gz>

```
dani@dani-VMware-Virtual-Platform:~$ wget https://downloads.apache.org/hadoop/co
mon/hadoop-3.3.6/hadoop-3.3.6.tar.gz
--2025-06-30 13:27:18-- https://downloads.apache.org/hadoop/common/hadoop-3.3.6
/hadoop-3.3.6.tar.gz
Resolving downloads.apache.org (downloads.apache.org)... 88.99.208.237, 135.181.
214.104, 2a01:4f8:10a:39da::2, ...
Connecting to downloads.apache.org (downloads.apache.org)|88.99.208.237|:443...
connected.
HTTP request sent, awaiting response... 200 OK
Length: 730107476 (696M) [application/x-gzip]
Saving to: 'hadoop-3.3.6.tar.gz'

hadoop-3.3.6.tar.gz  9%[>          ] 65.95M  9.60MB/s  eta 74s
```

5. Descomprimos el archivo que hemos obtenido con: `tar -xzf hadoop-3.3.6.tar.gz`. Podemos observar como en la carpeta personal tendremos la carpeta comprimida y descomprimida. Podemos eliminar la carpeta comprimida.



- Configuramos las variables de entorno: `nano ~/.bashrc`. Estas serian las variables de entorno para mi ruta en la carpeta personal. Deberiamos adaptar nuestras variables a nuestra ruta donde se encuentre hadoop.

```
export HADOOP_HOME=/home/dani/hadoop/hadoop-3.3.6
export PATH=$PATH:$HADOOP_HOME/bin:$HADOOP_HOME/sbin
export HADOOP_INSTALL=$HADOOP_HOME
export HADOOP_MAPRED_HOME=$HADOOP_HOME
export HADOOP_COMMON_HOME=$HADOOP_HOME
export HADOOP_HDFS_HOME=$HADOOP_HOME
export HADOOP_YARN_HOME=$HADOOP_HOME
export HADOOP_CONF_DIR=$HADOOP_HOME/etc/hadoop
export HADOOP_COMMON_LIB_NATIVE_DIR=$HADOOP_HOME/lib/native
export HADOOP_OPTS="-Djava.library.path=$HADOOP_HOME/lib/native"
```

- Las pegamos al final de nuestro archivo `bashrc`. Cerramos el archivo con `Ctrl + X` y guardamos.

```
dani@dani-VMware-Virtual-Platform: ~
GNU nano 7.2 /home/dani/.bashrc *
# enable programmable completion features (you don't need to enable
# this, if it's already enabled in /etc/bash.bashrc and /etc/profile
# sources /etc/bash.bashrc).
if ! shopt -oq posix; then
  if [ -f /usr/share/bash-completion/bash_completion ]; then
    . /usr/share/bash-completion/bash_completion
  elif [ -f /etc/bash_completion ]; then
    . /etc/bash_completion
  fi
fi
export HADOOP_HOME=/home/dani/hadoop/hadoop-3.3.6
export PATH=$PATH:$HADOOP_HOME/bin:$HADOOP_HOME/sbin
export HADOOP_INSTALL=$HADOOP_HOME
export HADOOP_MAPRED_HOME=$HADOOP_HOME
export HADOOP_COMMON_HOME=$HADOOP_HOME
export HADOOP_HDFS_HOME=$HADOOP_HOME
export HADOOP_YARN_HOME=$HADOOP_HOME
export HADOOP_CONF_DIR=$HADOOP_HOME/etc/hadoop
export HADOOP_COMMON_LIB_NATIVE_DIR=$HADOOP_HOME/lib/native
export HADOOP_OPTS="-Djava.library.path=$HADOOP_HOME/lib/native"
```

- Actualizamos el path con `:source ~/.bashrc`

9. Probamos con `which hadoop` para ver si se ha configurado correctamente en la ruta.

```
dani@dani-VMware-Virtual-Platform:~$ which hadoop
/home/dani/hadoop-3.3.6/bin/hadoop
dani@dani-VMware-Virtual-Platform:~$
```

10. Entramos en la carpeta de configuración siguiente: `cd $HADOOP_HOME/etc/hadoop` y abrimos con nano el archivo `hadoop-env.sh`

```
dani@dani-VMware-Virtual-Platform:~$ cd $HADOOP_HOME/etc/hadoop
dani@dani-VMware-Virtual-Platform:~/hadoop-3.3.6/etc/hadoop$ nano hadoop-env.sh
dani@dani-VMware-Virtual-Platform:~/hadoop-3.3.6/etc/hadoop$
```

```
dani@dani-VMware-Virtual-Platform: ~/hadoop-3.3.6/etc/hadoop$
GNU nano 7.2 hadoop-env.sh *
```

```
###
# Generic settings for HADOOP
###

# Technically, the only required environment variable is
# All others are optional. However, the defaults are
# preferred. Many sites configure these options outside
# such as in /etc/profile.d

# The java implementation to use. By default, this environment
# variable is REQUIRED on ALL platforms except OS X!
# export JAVA_HOME=

# Location of Hadoop. By default, Hadoop will attempt
# this location based upon its execution path.
# export HADOOP_HOME=
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
```

11. Por último configuramos los archivos XML. Los archivos son core-site.xml, hdfs-site.xml, mapred-site.xml y yarn-site.xml. Podemos abrirlos desde consola o desde la carpeta de hadoop. Los archivos están dentro de la carpeta hadoop en la carpeta etc.

Core-site.xml

```

dani@dani-VMware-Virtual-Platform: ~/Escritorio/hadoop/hadoop-3.3.6/e...
GNU nano 7.2                                core-site.xml
You may obtain a copy of the License at
http://www.apache.org/licenses/LICENSE-2.0

Unless required by applicable law or agreed to in writing, software
distributed under the License is distributed on an "AS IS" BASIS,
WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.
See the License for the specific language governing permissions and
limitations under the License. See accompanying LICENSE file.
-->

<!-- Put site-specific property overrides in this file. -->

<configuration>
  <property>
    <name>fs.defaultFS</name>
    <value>hdfs://localhost:9000</value>
  </property>
</configuration>

```

Hdfs-site.xml

```

dani@dani-VMware-Virtual-Platform: ~/Escritorio/hadoop/hadoop-3.3.6/e...
GNU nano 7.2                                hdfs-site.xml

<configuration>

  <property>
    <name>dfs.replication</name>
    <value>1</value>
  </property>

  <property>
    <name>dfs.namenode.name.dir</name>
    <value>file:///home/dani/hadoopdata/namenode</value>
  </property>

  <property>
    <name>dfs.datanode.data.dir</name>
    <value>file:///home/dani/hadoopdata/datanode</value>
  </property>

</configuration>

```

Mapred-site.xml

```
GNU nano 7.2 mapred-site.xml
<!-- Put site-specific property overrides in this file. -->
<configuration>
  <property>
    <name>mapreduce.framework.name</name>
    <value>yarn</value>
  </property>
  <property>
    <name>mapreduce.job.reduces</name>
    <value>1</value> <!-- Para salida ordenada -->
  </property>
  <property>
    <name>mapreduce.output.key.comparator.class</name>
    <value>org.apache.hadoop.mapreduce.lib.partition.KeyFieldBasedComparator</value>
  </property>
  <property>
    <name>mapreduce.partition.keycomparator.options</name>
    <value>-k1,1</value> <!-- Ordena por la clave (equipo) -->
  </property>
  <property>
    <name>mapreduce.application.classpath</name>
    <value>
      /home/dani/Escritorio/hadoop/hadoop-3.3.6/share/hadoop/common/*:/home/dani/Escritorio/hadoop/hadoop-3.3.6/share/h
    </value>
  </property>
</configuration>
```

Yarn-site.xml

```
GNU nano 7.2 yarn-site.xml
Unless required by applicable law or agreed to in writing, software
distributed under the License is distributed on an "AS IS" BASIS,
WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.
See the License for the specific language governing permissions and
limitations under the License. See accompanying LICENSE file.
-->
<configuration>
  <!-- Site specific YARN configuration properties -->

  <property>
    <name>yarn.nodemanager.aux-services</name>
    <value>mapreduce_shuffle</value>
  </property>

  <property>
    <name>yarn.nodemanager.env-whitelist</name>
    <value>JAVA_HOME,HADOOP_COMMON_HOME,HADOOP_HDFS_HOME,HADOOP_CONF_DIR,CLASSP
  </property>
</configuration>
```

12. Por último comprobamos que todos los demonios se ejecuten correctamente con el comando `start-yarn.sh` y `start-dfs.sh`.

```
dani@dani-VMware-Virtual-Platform:~$ start-yarn.sh
Starting resourcemanager
Starting nodemanagers
dani@dani-VMware-Virtual-Platform:~$ start-dfs.sh
Starting namenodes on [localhost]
Starting datanodes
Starting secondary namenodes [dani-VMware-Virtual-Platform]
dani@dani-VMware-Virtual-Platform:~$
```

Ejemplo de ejercicio MapReduce

1. Creamos un directorio en HDFS para el input: `hdfs dfs -mkdir -p /user/dani/input`
2. Copiamos el archivo de prueba al HDFS:
`echo "Hola Hadoop, Hadoop es genial. Hadoop es un framework para Big Data." > wordcount.txt`
`hdfs dfs -put wordcount.txt /user/dani/input/`
3. Ejecutamos el job WordCount

```
dani@dani-VMware-Virtual-Platform:~$ hadoop jar $HADOOP_HOME/share/hadoop/mapred
uce/hadoop-mapreduce-examples-3.3.6.jar wordcount /user/dani/input /user/dani/ou
tput
```

4. Vemos lo que nos devuelve la terminal:

```
Map-Reduce Framework
  Map input records=1
  Map output records=12
  Map output bytes=117
  Map output materialized bytes=125
  Input split bytes=116
  Combine input records=12
  Combine output records=10
  Reduce input groups=10
  Reduce shuffle bytes=125
  Reduce input records=10
  Reduce output records=10
  Spilled Records=20
  Shuffled Maps =1
  Failed Shuffles=0
  Merged Map outputs=1
  GC time elapsed (ms)=27
  CPU time spent (ms)=1440
  Physical memory (bytes) snapshot=582983680
  Virtual memory (bytes) snapshot=5447471104
  Total committed heap usage (bytes)=608174080
  Peak Map Physical memory (bytes)=331530240
```

Podemos observar como el trabajo de MapReduce se ha ejecutado correctamente generando un output = 10.

5. Ejecutamos el resultado por la terminal desde HDFS.

```
dani@dani-VMware-Virtual-Platform:~$ hdfs dfs -cat /user/dani/output/part-r-0000
0
Big      1
Data.    1
Hadoop   2
Hadoop,  1
Hola     1
es       2
framework      1
genial.  1
para     1
un       1
```

Vemos que funciona y nos genera un resultado coherente con nuestro input.